

هدف پروژه

این پروژه درباره ی حل یک مسئله طبقه بندی برای داده‌های مربوط به خودروها است. در این مسیر، ابتدا داده‌ها مورد بررسی و پیش‌پردازش قرار می‌گیرند تا مشکلاتی مانند داده‌های گمشده، داده‌های تکراری و مقادیر غیرعادی برطرف شوند و داده‌ها برای استفاده در مدل‌های یادگیری ماشین آماده شوند. سپس با استفاده از الگوریتم‌های طبقه‌بندی SVM و Decision Tree مدل‌هایی آموزش داده می‌شوند تا الگوهای موجود در داده‌ها را یاد بگیرند.

دیتاست

برای این پروژه، شما با یک دیتاست شامل مجموعه‌ای از خودروها کار خواهید کرد که ۹ کلاس مختلف از برندهای گوناگون را نمایش می‌دهد. این مجموعه شامل اطلاعات متنوعی از خودروهای موجود در بازار است؛ از جمله ویژگی‌هایی مانند سال تولید، نوع گیربکس، قیمت، کارکرد، نوع سوخت، مصرف سوخت و حجم موتور.

دیتایی که در اختیار شما قرار می‌گیرد شامل قسمت test و train جدا است و در داده test ستون manufacturer که label است حذف شده و پیشبینی آن به عهده شماست.

فاز اول (preprocess) :

در نخستین فاز پروژه، لازم است یک ارزیابی کلی از داده انجام دهید.

- بررسی وجود missing data
- بررسی داده تکراری و حذف آن
- بررسی مقادیر غیر عادی و حذف آنها
- بررسی نوع داده هر ستون و encoding در صورت نیاز
- نرمال سازی یا استاندارد سازی مقادیر ستون های عددی
- بررسی متعادل بودن یا نبودن کلاس ها و حل مشکل در صورت نامتعادل بودن

این فاز پایه‌ای برای مراحل بعدی است و تضمین می‌کند داده‌هایی که وارد مدل می‌شوند، کیفیت مناسب داشته باشند.

فاز دوم (آموزش مدل) :

گام بعدی شامل آموزش و ارزیابی مدل‌های پایه است. در این مرحله، دو مدل یادگیری ماشین شامل SVM و Decision Tree مورد استفاده قرار می‌گیرند. همچنین برای این فاز و برای مدل‌های آموزش داده شده، باید hyper-parameter tuning انجام دهید تا عملکرد مدل بهبود یابد.

پس از آموزش اولیه مدل‌ها، لازم است فرآیند Hyper-parameter Tuning انجام شود تا بهترین تنظیمات برای هر مدل پیدا شود و عملکرد آن‌ها بهبود یابد. این کار با آزمایش مقادیر مختلف برای پارامترهای مهم هر مدل انجام می‌شود تا در نهایت مدلی با دقت و کارایی بهتر به دست آید.

فاز سوم (ارزیابی مدل) :

معیارهای ارزیابی عملکرد زیر برای هر مدل بدست آورید:

- Confusion matrix
- F1score
- Precision
- Recall

موارد بدست آمده را در داکيومنت تحلیل کنید.

فاز چهارم (پیشبینی) :

با استفاده از مدل‌های آموزش دیده SVM و DT، لیبل‌های دیتای تست را پیشبینی کنید و در ۲ فایل CSV جدا با نام‌های SVM_label و DT_label ذخیره کنید. دقت کنید که مقادیر پیشبینی شده نام برند خودروها باشد، نه مقدار انکود شده آنها.

نکات تکمیلی

- علاوه بر سورس کد پروژه، فایل مستندات و لیبل‌های پیشبینی شده نیز باید آپلود شوند.
- فایل نهایی را در قالب فایل zip و با نام شماره دانشجویی خود آپلود کنید.
- نام اعضای گروه در مستندات ذکر شود و فقط یکی از اعضای گروه پروژه را آپلود کند.
- هرگونه شباهت نامتعارف بین کد شما و کد سایر گروه‌ها تقلب محسوب میشود و نمره ای برای پروژه دریافت نخواهید کرد.
- در صورت نوشتن داکيومنت تمیز (به طور مثال با latex) نمره اضافه در نظر گرفته میشود.

- در صورت داشتن هرگونه سوال میتوانید با @kourosh_hsz ، @arashazma ، @bhr_moh در بله در ارتباط باشید.