



دانشگاه فردوسی مشهد
گروه مهندسی کامپیوتر

گزارش پروژه درس

مبانی هوش محاسباتی

Vehicle Brand Classifier

دسته‌بندی چندکلاسه برند خودرو با SVM و درخت تصمیم

شماره دانشجویی	نام و نام خانوادگی
۴۰۲۲۶۲۰۳۵	امیرحسین ابوالفضلی
۴۰۲۱۶۲۱۳۱	آرمان بیجاری

استاد: دکتر فضل ارثی

نیمسال دوم ۱۴۰۵-۱۴۰۴

فهرست مطالب

۱	مقدمه	۲
۲	مجموعه داده	۲
۱.۲	توضیح کلی داده‌ها	۲
۲.۲	توزیع کلاس‌ها	۲
۳.۲	ویژگی‌های موجود	۳
۳	پیش‌پردازش	۳
۱.۳	پاک‌سازی داده	۳
۲.۳	مدیریت مقادیر پرت	۴
۳.۳	تبدیل لگاریتمی	۴
۴.۳	کدگذاری و نرمال‌سازی	۵
۵.۳	رفع عدم توازن کلاس‌ها با SMOTE	۵
۴	مدل‌سازی	۵
۱.۴	ماشین بردار پشتیبان (SVM)	۵
۲.۴	درخت تصمیم (Decision Tree)	۵
۵	تنظیم فرآیندها	۵
۱.۵	SVM	۶
۲.۵	درخت تصمیم	۶
۶	نتایج و ارزیابی	۶
۱.۶	معیارهای ارزیابی	۶
۲.۶	مقایسه مدل‌ها	۷
۳.۶	ماتریس درهم‌ریختگی	۷
۴.۶	اهمیت ویژگی‌ها	۹
۷	راه‌های بهبود	۱۰
۸	نتیجه‌گیری	۱۰

۱. مقدمه

هدف این پروژه پیش‌بینی برند خودرو بر اساس مشخصات بیان شده در دیتاست است. داده‌ها شامل اطلاعاتی مثل قیمت، نوع سوخت و اندازه موتور هستند و باید از روی این اطلاعات تشخیص داده شود که خودرو متعلق به کدام برند است.

این یک مسئله‌ی دسته‌بندی چندکلاسه (multiclass classification) است با ۹ کلاس (برند). برای حل آن از دو مدل استفاده شده: ساپورت وکتور ماشین (SVM) و درخت تصمیم (Decision Tree).

۲. مجموعه داده

۲.۱. توضیح کلی داده‌ها

دیتاست مورد استفاده به دو بخش تست و ترین تقسیم شده است که تعداد نمونه‌های آن به شرح زیر می‌باشد:

بخش	تعداد نمونه
آموزش	68,397
تست	29,314

جدول ۱: اندازه دیتاست

ستون هدف Manufacturer است که برند خودرو را مشخص می‌کند. ستون هدف در مجموعه تست وجود ندارد و باید توسط مدل پیش‌بینی شود.

۲.۲. توزیع کلاس‌ها

دیتاست شامل ۹ برند است: Audi، BMW، ford، hyundai، merc، skoda، toyota، vauxhall، volkswagen. توزیع کلاس‌ها یکنواخت نیست – ford بیشترین نمونه (حدود ۱۸٪) و hyundai کمترین (حدود ۵٪) را دارد.




شکل ۱: توزیع کلاس‌ها در مجموعه آموزش

۳.۲. ویژگی‌های موجود

هشت ویژگی ورودی وجود دارد که به دو دسته تقسیم می‌شوند:

ویژگی	نوع	توضیح
year	عددی	سال تولید خودرو
price	عددی	قیمت (پوند)
mileage	عددی	مایلکرد
tax	عددی	مالیات سالانه
mpg	عددی	مصرف سوخت
engineSize	عددی	حجم موتور (لیتر)
transmission	دسته‌ای	نوع گیربکس
fuelType	دسته‌ای	نوع سوخت

جدول ۲: ویژگی‌های ورودی



شکل ۲: توزیع ویژگی‌های عددی

۳. پیش‌پردازش


۱.۳. پاک‌سازی داده

اولین قدم بررسی کیفیت داده بود:

- مقادیر گم‌شده: هیچ مقدار گم‌شده‌ای در هیچ‌کدام از ستون‌ها وجود نداشت.
- ردیف‌های تکراری: یک ردیف تکراری در مجموعه آموزش پیدا و حذف شد.


۲.۳. مدیریت مقادیر پرت

با نگاه به توزیع ویژگی‌های عددی (نمودارهای باکس پلات)، مشخص شد که سه ستون price، mileage و mpg دارای مقادیر بسیار دور از میانه هستند.



شکل ۳: باکس پلات ویژگی‌های عددی قبل از پردازش

به جای حذف این نمونه‌ها، از روش کپینگ استفاده شد: مقادیر بالاتر از صدک ۹۹ام به همان صدک ۹۹ام و مقادیر پایین‌تر از صدک ۱ام به همان صدک ۱ام تنظیم شدند. این روش داده را حفظ می‌کند و فقط اثر افراطی مقادیر پرت را کاهش می‌دهد.



شکل ۴: باکس پلات بعد از کپینگ

۳.۳. تبدیل لگاریتمی

price و mileage هر دو توزیع چوله‌ی راست دارند – یعنی اکثر مقادیر کوچک هستند ولی تعداد کمی مقادیر خیلی بزرگ هم دارند. برای کاهش این چولگی، تبدیل $\log_{10}(x + 1)$ (یعنی $\ln(x + 1)$) روی این دو ستون اعمال شد. این کار به ویژه برای SVM مفید است چون این مدل مبتنی بر فاصله است و توزیع ویژگی‌ها تأثیر مستقیمی روی مرز تصمیم دارد.

۴.۳. کدگذاری و نرمال سازی

- ویژگی‌های دسته‌ای (transmission و fuelType): با OneHotEncoder به ستون‌های باینری تبدیل شدند.

- ویژگی‌های عددی: با StandardScaler نرمال سازی شدند (میانگین صفر، واریانس یک).

- برچسب هدف: با LabelEncoder به عدد تبدیل شد.

تمام این مراحل فقط روی داده‌های آموزش fit شدند و روی داده‌های اعتبارسنجی و تست فقط transform اعمال شد تا از نشت داده (data leakage) جلوگیری شود.

۵.۳. رفع عدم توازن کلاس‌ها با SMOTE

توزیع کلاس‌ها متوازن نبود. برای رفع این مشکل از SMOTE (Synthetic Minority Over-sampling Technique) استفاده شد. این روش نمونه‌های مصنوعی برای کلاس‌های اقلیت می‌سازد تا تعداد همه کلاس‌ها برابر شود. SMOTE فقط روی داده‌های آموزش اعمال شد — داده‌های اعتبارسنجی و تست هرگز oversample نشدند.

۴. مدل سازی

۱.۴. ماشین بردار پشتیبان (SVM)

SVM یک مدل مبتنی بر فاصله است که سعی می‌کند بهترین hyperplane برای جداسازی کلاس‌ها پیدا کند. در این پروژه از کرنل RBF استفاده شد که برای داده‌های غیرخطی مناسب‌تر است. پارامتر C کنترل می‌کند که مدل چقدر روی داده‌های آموزش سختگیری کند — مقادیر بزرگ‌تر C یعنی margin کوچک‌تر ولی خطای آموزش کمتر. پارامتر gamma تعیین می‌کند که هر نمونه چقدر روی مرز تصمیم تأثیر بگذارد.

۲.۴. درخت تصمیم (Decision Tree)

درخت تصمیم یک مدل قابل تفسیر است که داده را با پرسیدن سوال‌های if/else دسته‌بندی می‌کند. معیار entropy برای انتخاب بهترین ویژگی در هر گره استفاده شد. یکی از مزایای درخت تصمیم این است که به نرمال سازی ویژگی‌ها نیاز ندارد و می‌تواند اهمیت هر ویژگی را مستقیماً نشان دهد.

۵. تنظیم فرآپارامترها

برای هر دو مدل از GridSearchCV با 3-fold cross-validation استفاده شد. معیار بهینه سازی F1 weighted بود تا عدم توازن کلاس‌ها در نظر گرفته شود.

۱.۵. SVM

مقادیر جستجو شده	فرایارامتر
50, 100, 200, 300, 500	C
rbf	kernel
scale, auto, 0.01	gamma

جدول ۳: فضای جستجو برای SVM

بهترین پارامترها:

CV F1 score: 0.762 — C=500, kernel=rbf, gamma=scale

۲.۵. درخت تصمیم

مقادیر جستجو شده	فرایارامتر
gini, entropy	criterion
10, 15, 20, 30, None	max_depth
2, 5, 10	min_samples_split
1, 2, 5	min_samples_leaf

جدول ۴: فضای جستجو برای درخت تصمیم

بهترین پارامترها:

CV F1 — criterion=entropy, max_depth=30, min_samples_leaf=1, min_samples_split=2
score: 0.849

۶. نتایج و ارزیابی

۱.۶. معیارهای ارزیابی

برای سنجش عملکرد مدل‌ها از معیارهای زیر استفاده شد:

- **دقت (Accuracy):** نسبت پیش‌بینی‌های درست به کل نمونه‌ها.
 - **دقت (Precision):** از تمام نمونه‌هایی که مدل به یک کلاس نسبت داده، چند درصد واقعاً از آن کلاس بودند.
 - **فراخوانی (Recall):** از تمام نمونه‌های واقعی یک کلاس، چند درصد درست تشخیص داده شدند.
 - **F1 Score:** میانگین هارمونیک Precision و Recall.
- از دو نسخه F1 استفاده شد: weighted (وزن‌دهی بر اساس اندازه کلاس) و macro (میانگین ساده روی همه کلاس‌ها). F1 macro بهتر نشان می‌دهد که مدل روی کلاس‌های کوچک‌تر چقدر خوب عمل کرده.


۲.۶. مقایسه مدل‌ها

مدل	دقت	F1 weighted	F1 macro	بهبود
SVM پایه	59.14%	0.591	0.579	—
SVM تنظیم‌شده	73.03%	0.732	0.721	+13.89%
درخت تصمیم پایه	80.07%	0.802	0.791	—
درخت تصمیم تنظیم‌شده	81.25%	0.813	0.802	+1.18%


جدول ۵: مقایسه عملکرد مدل‌ها روی مجموعه اعتبارسنجی

درخت تصمیم در هر دو حالت پایه و تنظیم‌شده عملکرد بهتری نسبت به SVM دارد. SVM از تنظیم فراپارامتر سود بیشتری برد (+13.89%) در مقابل درخت تصمیم که از ابتدا هم نتایج خوبی داشت.


۳.۶. ماتریس درهم‌ریختگی




شکل ۵: ماتریس درهم‌ریختگی مدل‌های پایه



شکل ۶: ماتریس درهم‌ریختگی SVM تنظیم‌شده




شکل ۷: ماتریس درهم‌ریختگی درخت تصمیم تنظیم‌شده



شکل ۸: مقایسه ماتریس درهم‌ریختگی دو مدل تنظیم‌شده

نکته‌ای که از ماتریس‌های درهم‌ریختگی به خوبی پیداست این است که skoda و volkswagen بیشترین اشتباه را دارند – مدل‌ها این دو برند را با هم اشتباه می‌گیرند. دلیل آن هم کاملاً منطقی است: هر دو برند آلمانی هستند، محدوده قیمتی مشابهی دارند و مشخصات فنی‌شان (اندازه موتور، مصرف سوخت) خیلی به هم نزدیک است.

۴.۶. اهمیت ویژگی‌ها



شکل ۹: اهمیت ویژگی‌ها در درخت تصمیم تنظیم‌شده

سه ویژگی اول با اختلاف مهم‌ترین نقش را دارند:

اهمیت	ویژگی
27.6%	engineSize
26.3%	mpg
18.7%	price
7.6%	mileage
6.7%	year
13.1%	بقیه

جدول ۶: اهمیت ویژگی‌ها

این نتیجه کاملاً منطقی است – اندازه موتور و مصرف سوخت تفاوت‌های واضحی بین برندها دارند. مثلاً Audi و BMW معمولاً موتورهای بزرگ‌تری نسبت به vauxhall یا ford دارند.

۷. راه‌های بهبود

چند مسیر برای بهبود نتایج وجود دارد که در این پروژه انجام نشده‌اند:

- **مهندسی ویژگی:** اضافه کردن ستون مدل خودرو (model) در صورت وجود می‌تواند قدرت پیش‌بینی را به شکل چشمگیری بالا ببرد، چون هر برند مدل‌های منحصر به فردی دارد.
- **مدل‌های قوی‌تر:** مدل‌هایی مثل Random Forest یا XGBoost معمولاً روی داده‌های جدولی عملکرد بهتری نسبت به درخت تصمیم تکی دارند.
- **رفع سردرگمی Skoda و VW:** این دو برند بیشترین اشتباه را دارند. یک راه‌حل ممکن آموزش یک مدل تخصصی فقط برای تفکیک این دو برند است.
- **جستجوی هوشمندتر فرایارامتر:** به جای GridSearchCV، استفاده از RandomizedSearchCV یا Bayesian Optimization می‌تواند فضای بزرگ‌تری را در زمان کمتری کاوش کند.

۸. نتیجه‌گیری

در این پروژه یک pipeline کامل برای دسته‌بندی برند خودرو از روی مشخصات آگهی فروش پیاده‌سازی شد. درخت تصمیم با دقت ۸۱.۲۵٪ بهترین نتیجه را داشت. SVM هم بعد از تنظیم به ۷۳.۰۳٪ رسید که نسبت به حالت پایه‌اش بهبود قابل توجهی بود.

مهم‌ترین نکته‌ای که از این پروژه یاد گرفتیم این است که **پیش‌پردازش درست** خیلی مهم‌تر از انتخاب مدل است. مدیریت مقادیر پرت، تبدیل لگاریتمی، و رفع عدم توازن کلاس‌ها همگی نقش مستقیمی در بهبود نتایج داشتند.

سه ویژگی engineSize، mpg و price با هم بیش از ۷۲٪ از قدرت تصمیم‌گیری مدل را تشکیل می‌دهند که نشان می‌دهد برندهای مختلف عمدتاً از نظر این سه ویژگی از هم متمایز هستند.